

DDQM2-like Heavy Prototype 실험 보고서

작성일: 2026-05-04

프로젝트: `autoquant-lab`

실험 ID: `ddqm2_like_150_2015_2025_lgbm`

1. 한눈에 보는 결론

이번 실험은 “진짜 연구용 최종 실험”이라기보다는, **DDQM2와 비슷한 구조를 yfinance 공개 데이터로 크게 한번 돌려본 prototype 실험**입니다. 이전에는 3개 종목, 6개월 데이터로 아주 작은 smoke test만 했는데, 이번에는 150개 종목과 약 11년치 데이터를 사용했습니다.

결론부터 말하면 다음과 같습니다.

- 파이프라인은 큰 규모에서도 끝까지 정상적으로 돌아왔습니다.
- LightGBM은 단순 baseline보다 RMSE와 MAE에서 **아주 조금 더 좋았습니다**.
- 다만 개선 폭이 작고 `best_iteration=1` 이라, “강한 alpha를 찾았다”고 말하기에는 아직 부족합니다.
- 따라서 이번 결과는 **모델 성과 자랑용**이 아니라, “DDQM2-like 구조가 더 큰 데이터에서도 작동한다”는 확인에 가깝습니다.

쉽게 표현하면 이렇습니다.

이번 실험은 엔진이 켜지고 도로 주행까지 되는지 확인한 단계입니다. 차가 엄청 빠르다는 결론은 아직 아닙니다.

2. 이번 실험이 하려는 일

DDQM2 스타일의 핵심 아이디어는 대략 다음과 같습니다.

- 시장의 macro 상태를 본다.
- 여러 factor가 앞으로 좋아질지 나빠질지 예측한다.
- 그 예측을 바탕으로 factor long-short return을 모델링한다.

여기서 factor long-short return은 “특정 factor 점수가 높은 종목 묶음은 사고, 낮은 종목 묶음은 판 것처럼 계산한 수익률”입니다. 예를 들어 momentum factor라면, momentum이 높은 종목군과 낮은 종목군의 차이를 보는 식입니다.

이번 실험에서 확인한 질문은 이것입니다.

FRED/ALFRED macro feature를 사용해서 **factor long-short return**을 예측하는 **DDQM2-like pipeline**이, **smoke test**보다 훨씬 큰 데이터에서도 제대로 작동할까?

구체적으로는 아래 흐름을 모두 확인했습니다.



3. 사용한 데이터 범위

이번 실험은 WRDS 없이 공개 데이터로 만든 prototype입니다. 그래서 데이터 규모는 키웠지만, 데이터 품질은 여전히 연구급 WRDS 데이터와 다릅니다.

항목	설정
Universe	Wikipedia S&P 500 current-membership 중 앞쪽 150개 종목
가격 데이터	yfinance
Macro feature	기존 <code>expanded_macro_market_features.xlsx</code> 의 FRED/ALFRED/yfinance macro-market features
기간	2015-01-01 ~ 2025-12-31
Formation date	월말 기준
예측 horizon	21 trading days
Long basket	factor 상위 20%
Short basket	factor 하위 20%
최소 basket 크기	long/short 각각 25개 이상
검증 방식	시간순 holdout, random split 없음

중요한 점은 **random split**을 쓰지 않았다는 것입니다. 금융 시계열에서 random split을 쓰면 미래 정보가 과거 학습에 섞일 수 있기 때문에, 이번에는 과거 구간으로 학습하고 더 최근 구간으

로 검증했습니다.

4. 생성된 artifact 규모

이번 실험은 smoke test와 비교하면 꽤 큰 artifact를 만들었습니다.

Artifact	Rows	Columns	쉽게 말하면
Price panel	402,384	21	150개 종목의 일별 가격/거래량 정리표
Factor scores	5,889,549	16	종목별 factor 점수 대량 계산 결과
Factor long-short labels	1,919	21	월별 factor 수익률 target
Macro-factor model dataset	1,919	96	LightGBM에 넣을 최종 학습 테이블
LightGBM experiment	1,919 predictions	-	metric, prediction, feature importance, manifest

여기서 가장 큰 테이블은 factor score입니다. 일별·종목별·factor별 점수를 모두 만들기 때문에 589만 rows까지 늘어났습니다. 하지만 최종 모델 학습은 월말 factor label 기준이라 1,919 rows로 압축됩니다.

5. 어떤 factor를 만들었나

이번 run에서는 총 15개 factor를 만들었습니다.

Factor family	Factors
Momentum	mom_1m, mom_3m, mom_6m, mom_12m
Reversal	rev_1w, rev_1m
Volatility	vol_1m, vol_3m, vol_6m
Drawdown	max_dd_1m, max_dd_3m, max_dd_6m
Liquidity / volume	dollar_volume_1m, volume_z_1m, amihud_illiq_1m

주의할 점이 하나 있습니다. 이번 universe에는 SPY가 포함되지 않았습니다. 그래서 beta_spy_6m, corr_spy_6m처럼 SPY 대비 민감도를 계산하는 factor는 빠졌습니다.

다음 실험에서는 custom universe CSV에 SPY를 따로 넣으면 market-sensitivity factor까지 포함할 수 있습니다.

6. LightGBM 설정

이번에는 smoke mode가 아니라 non-smoke 설정으로 돌렸습니다.

Parameter	Value
Mode	non-smoke
Train rows	1,514
Validation rows	405
Train period	2015-01-30 ~ 2023-08-31
Validation period	2023-09-29 ~ 2025-11-28
Target	target_long_short_return
n_estimators	2,000
learning_rate	0.02
num_leaves	31
early_stopping_rounds	100
best_iteration	1
Validation split	최신 20% formation dates

설정 자체는 smoke보다 훨씬 강하게 잡았습니다. n_estimators=2000 으로 충분히 많은 boosting round를 허용했고, learning_rate=0.02 로 천천히 학습하게 했습니다. 또 early stopping을 100으로 두어 validation 성능이 좋아지지 않으면 멈추게 했습니다.

다만 결과적으로 best_iteration=1 이 나왔습니다. 이 말은 “나무를 많이 쌓아도 validation 성능이 좋아지지 않았고, 사실상 초반 1번째 iteration이 가장 좋았다”는 뜻입니다. 모델이 복잡해질수록 검증 구간에서는 별 도움이 안 됐다는 신호입니다.

7. 성능 결과

아래 표는 validation 구간에서의 결과입니다. RMSE와 MAE는 낮을수록 좋습니다. IC는 예측값과 실제값의 상관 방향을 보는 지표로, 높을수록 좋습니다.

Model	RMSE	MAE	R2	Pearson IC
LightGBM	0.0586885	0.0463509	-0.0095	0.0941
train_mean_return	0.0587224	0.0463885	-0.0107	~0.0000
zero_return	0.0592602	0.0468195	-0.0293	n/a
last_factor_return	0.0769387	0.0599520	-0.7350	0.1376

쉽게 해석하면

LightGBM이 제일 좋은 RMSE와 MAE를 냈습니다. 그래서 “모델이 아예 아무것도 못 한 것은 아닙니다”라고 볼 수 있습니다.

하지만 개선 폭은 매우 작습니다.

- LightGBM vs train mean RMSE 개선: 약 0.0000339
- LightGBM vs zero return RMSE 개선: 약 0.0005717
- LightGBM validation IC: 0.0941

즉, LightGBM이 baseline보다 근소하게 앞서기는 했지만, 압도적인 차이는 아닙니다. 특히 train_mean_return 과 거의 비슷하기 때문에, 현재 상태에서는 “macro feature가 factor return을 강하게 예측한다”고 말하기 어렵습니다.

좋게 말하면:

대형 **prototype pipeline**은 정상 작동했고, **LightGBM**도 **baseline**보다 아주 조금 나왔다.

조심스럽게 말하면:

아직 성과라고 부르기에는 약하다. 다음 실험에서 **factor 확장**, 모델 **regularization**, **walk-forward validation**이 필요하다.

8. Smoke test와 비교하면 얼마나 커졌나

이번 run이 “빡센 run”인지 확인하려면 기존 smoke test와 비교하면 됩니다.

항목	기존 smoke	이번 heavy prototype
Assets	3	150
기간	2020-01 ~ 2020-06	2015-01 ~ 2025-12
Price panel rows	372	402,384
Factor score rows	3,447	5,889,549
Label rows	46	1,919
Train rows	33	1,514
Validation rows	13	405
n_estimators	25	2,000
early_stopping_rounds	5	100

이 비교만 보면 이번 실험은 smoke가 아닙니다. 훨씬 더 큰 prototype run입니다. 다만 “더 크다”와 “연구급이다”는 다른 말입니다. 데이터가 여전히 yfinance/current-membership 기반이기 때문입니다.

9. 해석할 때 조심해야 할 부분

이 섹션은 결과를 부정하려는 부분이 아니라, 결과를 어디까지 믿어도 되는지 경계선을 그어두는 부분입니다. 숫자가 나왔다는 사실보다, 그 숫자가 어떤 데이터와 어떤 가정에서 나왔는지가 더 중요합니다.

9.1 데이터 쪽 한계

- **현재 S&P 500 구성종목 기준입니다.** 과거 특정 시점의 실제 S&P 500 universe가 아니라서 survivorship bias가 남아 있습니다.
- **WRDS를 쓰지 않았습니다.** CRSP delisting return, PERMNO/PERMCO, Compustat GVKEY, IBES link가 아직 없습니다.
- **yfinance는 prototype용 데이터입니다.** 가격/거래량 pipeline을 점검하기에는 유용하지만, 연구용 source of truth로 보기에는 부족합니다.

왜 중요하냐면, 실제 과거에 존재했다가 사라진 종목이나 delisting return이 빠지면 factor return이 실제보다 좋아 보이거나 다르게 보일 수 있기 때문입니다.

9.2 Feature와 target 쪽 한계

- **Macro feature의 완전한 point-in-time 보장이 부족합니다.** 일부 feature는 실제 발표 시점 기준으로 완벽하게 재현되지 않았을 수 있습니다.

- 월별 **target sample**이 아주 큰 편은 아닙니다. 11년치라고 해도 factor-month 기준으로 1,919 rows입니다.

이 말은 모델이 학습할 수 있는 “정답 샘플”이 생각보다 많지 않다는 뜻입니다. 그래서 결과가 특정 기간이나 특정 factor 조합에 민감할 수 있습니다.

9.3 모델 쪽 한계

- **best_iteration=1** 이 나왔습니다. 모델을 더 깊게 학습해도 validation 성능이 좋아지지 않았다는 신호입니다.
- LightGBM이 baseline보다 조금 좋았지만, 차이가 작습니다.

따라서 이번 결과는 “모델이 전혀 작동하지 않는다”는 뜻은 아닙니다. 오히려 pipeline은 잘 연결됐고 baseline보다도 약간 나왔습니다. 다만 아직은 성과 주장보다 다음 실험 설계를 위한 출발점으로 보는 것이 더 안전합니다.

10. 다음 실험 제안

이번 결과를 바탕으로 다음은 아래 순서가 좋습니다.

10.1 Universe에 SPY 추가

SPY를 custom universe에 넣어서 `beta_spy_6m`, `corr_spy_6m` factor를 살립니다. 시장 민감도 factor가 빠져 있으면 DDQM2-like factor set이 조금 빈약해집니다.

기대 효과는 간단합니다. 시장 전체 움직임에 대한 민감도를 factor로 넣으면, 단순 가격/거래량 factor만 있을 때보다 macro 환경과 factor return의 연결을 더 잘 볼 수 있습니다.

10.2 LightGBM regularization 옵션 추가

현재 training script는 CLI에서 `max_depth`, `min_child_samples`, `subsample`, `colsample_bytree`, `reg_lambda`를 직접 받지 않습니다. 다음 코드 개선에서는 이 옵션들을 추가하는 것이 좋습니다.

추천 후보는 다음과 같습니다.

Parameter	Suggested Values
num_leaves	15, 31
max_depth	3, 5
min_child_samples	30, 50
subsample	0.8
colsample_bytree	0.8
reg_lambda	1.0, 5.0
learning_rate	0.01, 0.02
n_estimators	2,000 ~ 3,000 with early stopping

기대 효과는 과적합을 줄이는 것입니다. 이번 run에서 `best_iteration=1` 이 나온 만큼, 모델을 더 크게 만드는 것보다 더 보수적으로 제한하는 방향이 먼저입니다.

10.3 Walk-forward validation

이번에는 단일 time holdout만 했습니다. 다음에는 expanding-window 또는 rolling-window validation을 추가해서 결과가 특정 기간에만 우연히 나온 것인지 확인해야 합니다.

기대 효과는 성능의 안정성 확인입니다. 한 번의 holdout에서 조금 좋아 보이는 결과가 여러 기간에서도 반복되는지 확인할 수 있습니다.

10.4 WRDS adapter로 교체

최종 목표는 yfinance를 CRSP/Compustat/IBES 기반 source adapter로 바꾸는 것입니다. 이때 downstream factor, label, model, dashboard layer는 지금 만든 canonical schema를 최대한 재사용하면 됩니다.

기대 효과는 연구 신뢰도 개선입니다. WRDS 기반으로 바뀌면 survivorship bias, delisting return, point-in-time link 문제를 훨씬 더 정확하게 다룰 수 있습니다.

11. 최종 요약

이번 실험은 **DDQM2-like prototype heavy run**으로는 성공입니다.

성공이라고 보는 이유는 다음과 같습니다.

- 150개 종목과 11년치 데이터로 price panel을 만들었습니다.
- 589만 rows 규모의 factor score를 생성했습니다.
- 월별 factor long-short label을 만들었습니다.
- macro feature와 factor label을 결합했습니다.

- non-smoke LightGBM을 돌리고 baseline과 비교했습니다.
- 모든 주요 artifact validation을 통과했습니다.

하지만 모델 성능은 아직 조심스럽게 봐야 합니다.

파이프라인은 더 큰 규모에서도 작동한다. 다만 **alpha**라고 부르기에는 아직 약하다. 다음 단계는 **SPY** 포함 **factor** 확장, **regularized LightGBM** 옵션 추가, **walk-forward validation**, 그리고 **WRDS** 기반 데이터 교체다.

이 보고서의 결론은 “좋은 성과를 냈다”가 아니라, **좋은 실험 기반을 만들었다**입니다.